

Kimi K3 브리핑

오픈웨이트로 열린 프런티어 AI — 기술, 비즈니스, 그리고 파트너 전략

Jihwan Woo, Sr. Specialist SA AIML

2026년 7월 22일

Abstract

2026년 7월 16일, 중국 문샷AI(Moonshot AI)가 공개한 Kimi K3는 “최상위 성능의 AI 모델은 소수 기업의 폐쇄형 API로만 쓸 수 있다”는 업계의 오랜 전제를 흔들고 있다. 본 문서는 K3가 무엇인지 비전문가도 이해할 수 있게 설명하고, 기술적 진보의 핵심, 기업 관점의 비즈니스 의미, 그리고 AWS 파트너 생태계 관점에서 우리가 해야 할 기술적·비즈니스적 과제를 정리한다.

1. 한눈에 보는 Kimi K3

Kimi K3를 한 문장으로 요약하면 이렇다. **“미국 최상위 모델에 근접한 성능의 초대형 AI를, 누구나 내려받아 쓸 수 있는 형태(오픈웨이트)로 공개한 첫 사례.”**

- **개발사:** 문샷AI (Moonshot AI, 중국 베이징 소재 스타트업)
- **공개일:** 2026년 7월 16일 서비스 개시, 7월 27일까지 모델 가중치 전체 공개 예고
- **규모:** 총 2조 8,000억 개 파라미터 — 오픈웨이트 모델 중 최대. 종전 최대였던 딥시크 V4 Pro(1조 6,000억 개)보다 약 75% 크다. 참고로 Claude, GPT 등 폐쇄형 모델은 파라미터 수 자체를 공개하지 않아 직접 비교는 불가능하다.
- **특징:** 한 번에 100만 토큰(AI가 글을 처리하는 단위로, 단어보다 조금 짧다. 100만 토큰이면 책 여러 권 분량)을 다루는 긴 문맥 처리, 텍스트와 이미지를 하나의 모델로 함께 학습한 멀티모달 지원, 장시간 자율 작업(에이전트) 지향
- **성능 위치:** 독립 평가기관 Artificial Analysis 지능 지수 57점으로 전체 3위. Claude Fable 5(60점), GPT-5.6 Sol(59점)에는 못 미치지만 Claude Opus 4.8(56점)을 앞서는 수준

문샷AI 스스로도 “가장 강력한 폐쇄형(proprietary) 모델에는 아직 뒤진다”고 인정한다. 그런데도 시장이 술렁인 이유는, 그 격차가 역대 가장 좁아진 상태에서 모델의 가중치(*weight*)가 공개되기 때문이다. 언론에서는 2025년 초의 딥시크(DeepSeek) 충격에 빗대 “제2의 딥시크”라 부르지만, 성격은 다르다. 딥시크가 “이렇게 싸게 만들 수 있다”는 비용 충격이었다면, K3는 “이 수준의 성능을 공개해 버린다”는 개방 충격에 가깝다.

1.1 용어 정리: 폐쇄형(proprietary) 모델 vs 오픈웨이트 모델

이 글을 이해하는 데 필요한 핵심 구분은 모델 가중치를 내려받을 수 있는가이다. 가중치란 학습을 통해 결정된 수십억~수조 개의 숫자 값으로, 모델의 능력 그 자체를 담고 있는 데이터다.

폐쇄형(proprietary) 모델은 개발사가 가중치를 비공개로 보유하고, 사용자는 API를 통해서만 모델을 호출할 수 있다. Claude, GPT 계열이 여기에 해당한다. 오픈웨이트 모델은 가중치 파일을 공개해, 누구나 내려받아 자신의 인프라에서 실행하거나 추가 학습에 사용할 수 있다. K3가 여기에 해당한다.

2. K3의 세 가지 핵심 특징

2.1 2.8조 파라미터, 그러나 매번 다 쓰지는 않는다

K3는 MoE(Mixture of Experts) 구조를 쓴다. 모델 내부가 896개의 전문가 모듈로 나뉘어 있고, 입력된 단어(토큰) 하나를 처리할 때는 그중 가장 적합한 16개만 선택해 계산한다. 전체 파라미터의 약 1.8%만 활성화되는 셈이다. 따라서 2.8조라는 총 규모에 비해 한 번의 응답에 드는 실제 계산 비용은 훨씬 작다. 총 파라미터 수는 모델이 담을 수 있는 지식의 양에, 활성 파라미터 수는 응답 한 번의 비용에 가깝다고 이해하면 된다.

2.2 100만 토큰 문맥

K3는 한 번에 100만 토큰, 대략 책 여러 권 분량의 텍스트를 유지한 채 작업할 수 있다. 수만 줄의 코드베이스나 수백 쪽의 계약서 문치를 잘라서 나눠 입력하지 않아도, 전체 내용을 참조하며 답할 수 있다는 뜻이다. 다만 긴 문맥 모델은 일반적으로 문맥이 길어질수록 내용을 놓칠 확률이 올라가므로, 100만 토큰 전 구간에서 품질이 유지되는지는 실측으로 확인할 부분이다.

2.3 더 길게 일하는 에이전트

목표를 받으면 자료를 찾고, 코드를 실행하고, 결과를 확인해 고치는 과정을 스스로 반복하는 **에이전트** 능력은 이제 최신 프런티어 모델들의 공통된 지향이다. K3가 내세우는 차별점은 그 자율 작업을 얼마나 오래, 사람의 개입 없이 지속할 수 있는가에 있다. 문샷AI가 공개한 시연 사례들은 시간 단위가 아니라 하루 이상 단위다.

- 최대 24시간 동안 GPU 연산 코드를 스스로 고치며 성능을 끌어올림
- ‘MiniTriton’이라는 소형 GPU 컴파일러를 처음부터 끝까지 직접 개발
- 오픈소스 반도체 설계 도구로 48시간 만에 소형 AI 칩을 설계·시뮬레이션
- 논문 20여 편을 검토하고 3,000줄 이상의 분석 코드를 작성해 천체물리 연구 결과를 재현 — 숙련 연구자의 1~2주 분량을 약 2시간에

단, 이 사례들은 모두 개발사가 직접 선별해 공개한 것이다. 몇 번 시도해서 성공했는지, 실패율이 얼마인지는 공개되지 않았으므로, “이런 종류의 일을 시키려는 모델”이라는 방향성의 증거로 읽는 것이 적절하다.

3. 기술적으로 무엇이 새로운가

K3의 새로움은 어떤 하나의 신기술이 아니라, **계산을 아끼는 선택들을 최고 성능급 모델에서 동시에 해냈다는** 데 있다. 방향은 세 가지다. 긴 문서를 읽을 때 모든 단어를 서로 비교하는 대신 계산량이 훨씬 천천히 늘어나는 방식을 쓰고(KDA), 2.8조 개의 파라미터 중 매번 필요한 1.8%만 골라서 계산하며(LatentMoE), 숫자를 저장할 때도 π 를 3.141592...까지 쓰지 않고 3으로 줄여 쓰듯 정밀도를 낮춰 공간과 비용을 아꼈다(MXFP4).

하나 하나는 알려진 아이디어지만, 이 조합을 최상위 규모에서 품질 저하 없이 성공시켰다는 것이 문샷AI의 주장이며, 독립 평가 점수가 이를 상당 부분 뒷받침한다. (각 기술의 상세한 설명과 개념도는 부록 A 참조)

이런 선택의 배경도 주목할 만하다. 미국의 반도체 수출 규제로 중국 기업들은 최신 GPU를 마음껏 쓸 수 없다. 컴퓨팅을 더 할 수 없다면 같은 컴퓨팅에서 더 많은 것을 뽑아내는 수밖에 없고, K3의 설계 전체가 그 답이다. “결핍이 발명을 낳았다”는 학계의 평가(Nature 인용)가 나오는 이유다.

4. 성능 평가

4.1 독립 평가 기준의 위치

Artificial Analysis 지능 지수(코딩, 추론, 에이전트 작업 등 9개 독립 평가를 종합한 0-100점 지표)에서 K3는 57점으로 전체 3위다. 1위 Claude Fable 5(60점), 2위 GPT-5.6 Sol(59점)보다는 낮지만, Claude Opus 4.8(56점), GPT-5.5를 앞선다. 오픈웨이트 모델이 이 위치에 오른 것은 처음이다. 개발사 자체 평가에서는 33개 공개 벤치마크 중 8개에서 1위 또는 공동 1위였고, 특히 장시간 코딩(SWE Marathon), 웹 탐색(BrowseComp), 문서 이해(OmniDocBench)에서 강했다.

4.2 해석 시 주의점

- **속도와 비용**: 출력 속도는 초당 40토큰대로 경쟁 모델 대비 느린 편이고, 추론(thinking)을 최대한으로 쓰는 기본 설정 탓에 토큰 소모가 많다.
- **개발사가 인정한 한계**: 대화 중간에 다른 모델에서 K3로 전환하면 품질이 불안정해질 수 있고, 모호한 지시를 받으면 사용자를 대신해 과감한(때로 과한) 결정을 내리는 경향이 있다.

요컨대 “미국 AI를 넘어섰다”는 단정은 이르지만, “공개 모델이 최상위 경쟁권에 진입했다”는 사실은 복수의 독립 평가로 뒷받침된다.

5. 비즈니스 관점: 무엇이 달라지는가

5.1 오픈소스가 아니라 ‘오픈웨이트’

K3는 학습을 마친 모델의 가중치(두뇌 그 자체)를 내려받아 자체 인프라에서 돌리거나 추가 학습할 수 있게 공개된다. 다만 학습 데이터와 학습 코드까지 공개되는 것은 아니므로 엄밀히는 오픈소스가 아니라 오픈웨이트다. 기업 입장에서 실질적 의미는 세 가지다.

1. **데이터 통제권**: 민감한 데이터를 외부 API로 보내지 않고 자사 통제 하의 인프라에서 처리할 수 있다.
2. **커스터마이징**: 산업·업무 특화 미세조정(fine-tuning)이 가능하다. 폐쇄형 API에서는 제한적인 옵션이다.
3. **벤더 종속 완화**: 특정 기업의 가격·정책 변경, 접근 차단 리스크에 대한 헤지가 된다. 실제로 지난달 미국 정부 지시로 일부 최상위 모델의 해외 접근이 일시 차단된 사례가 있었다.

5.2 ‘무료로 쓸 수 있다’는 착각은 금물: 숫자로 보는 자체 운영의 벽

가중치가 공개되더라도 자체 운영은 만만치 않다. K3의 2.8조 파라미터는 가장 압축된 4비트(MXFP4) 형식으로도 가중치만 약 1.4TB에 달한다. 반도체 분석기관 SemiAnalysis에 따르면 이는 NVIDIA의 최신 8-GPU

서버 DGX B200 한 대에도 들어가지 않는 크기로, GPU당 메모리 288GB급인 B300, AMD MI355X, 또는 GB300 NVL72 같은 최신 시스템이 필요하다. 문샷AI 역시 효율적 구동을 위해 64개 이상의 가속기로 구성된 슈퍼노드 환경을 권장한다. 이것이 실제로 어떤 비용인지 AWS 온디맨드 단가 기준으로 정리하면 다음과 같다.

GPU 구성	AWS 인스턴스	메모리 합계	K3 구동	시간당 요금
H100 × 8	P5	0.64 TB	불가	\$42 (약 5.8만 원)
H200 × 8	P5en	1.13 TB	불가	\$55 (약 7.7만 원)
B200 × 8	P6-B200	1.44 TB	사실상 불가*	\$99 (약 13.9만 원)
B300 × 8	P6-B300	2.30 TB	최소 구동	\$112 (약 15.7만 원)
B300 × 64	P6-B300 (권장)	18.4 TB	권장 구성	\$899 (약 126만 원)

Table 1: K3 자체 호스팅에 필요한 GPU 구성과 비용 추정. 2026년 7월 1일 인상 후 AWS GPU당 온디맨드 단가(P5 \$5.19, P5en \$6.87, P6-B200 \$12.36, P6-B300 \$14.04) 기준, 환율 1,400원/달러. EC2는 사용한 시간만큼만 과금되며, 장기 약정 시 단가는 30–60% 낮아진다. *가중치는 간신히 들어가지만 100만 토큰 문맥의 KV 캐시 등 실행 메모리를 감안하면 실용적이지 않다는 것이 SemiAnalysis의 분석이다. 가중치 공개 전 추정치이므로 공개 후 실측 검증이 필요하다.

시간당 126만 원이라는 권장 구성 요금이 말해주듯, 어떤 요금제로 낮추더라도 최소 진입선이 최신 GPU 서버 여러 대라는 사실은 변하지 않는다. 대다수 기업에게 현실적인 경로는 직접 운영이 아니라, 클라우드나 전문 추론 사업자가 호스팅한 K3를 토큰 단위로 사서 쓰는 것이다.

5.3 API 가격 구조

혼동을 피하기 위해 분명히 하면, 오픈웨이트인 K3는 가중치를 내려받아 자체 인프라에서 직접 돌리는 경우 문샷AI에 낼 돈이 전혀 없다. 라이선스비도 토큰비도 없다. 아래의 토큰당 과금은 직접 돌리는 대신 문샷AI가 자기 서버에 호스팅해 둔 K3를 API로 쓸 경우에 내는 이용료다. 즉 기업의 선택지는 둘이다. 앞 절의 GPU 비용을 직접 감당하며 토큰비 없이 쓰거나, 인프라 부담 없이 호스팅된 K3를 쓴 만큼 내고 쓰거나. 후자의 단가를 동급 폐쇄형 모델과 비교하면 다음과 같다.

모델	입력(100만 토큰당)	캐시 적용 시	출력(100만 토큰당)
Kimi K3 (오픈웨이트)	\$3.00 (4,200원)	\$0.30 (420원)	\$15.00 (2.1만 원)
GPT-5.6 Sol (폐쇄형)	\$5.00 (7,000원)	—	\$30.00 (4.2만 원)
Claude Fable 5 (폐쇄형)	\$10.00 (1.4만 원)	—	\$50.00 (7.0만 원)

Table 2: 공식 API 단가 비교(2026년 7월 기준, 각사 발표 가격, 환율 1,400원/달러). 캐시 적용이란 직전에 보낸 것과 같은 입력(예: 대화 이력, 문서 원문)을 다시 보낼 때 저장된 처리 결과를 재사용해 90% 할인된 단가가 적용되는 것을 말한다. 동일 작업량 기준 K3는 GPT-5.6 Sol의 약 절반, Claude Fable 5의 약 3분의 1 수준이다.

다만 단가가 싸다고 최종 비용도 싼 것은 아니다. K3는 답을 내놓기 전에 내부적으로 긴 풀이 과정을 거치는 방식으로 동작하며, 출시 시점에는 이 풀이의 길이가 가장 긴 설정으로 고정되어 있다. 풀이 과정도 토큰으로 과금되므로, 같은 질문에 대해 경쟁 모델보다 더 많은 토큰을 소모한다. 토큰당 가격이 절반이어도 토큰을 2배 쓰면 최종 비용은 같아지는 셈이다.

그래서 도입 검토 시에는 토큰 단가가 아니라 작업 하나를 끝내는 데 드는 총비용(TCO)으로 비교해야 한다. 독립 평가기관 Artificial Analysis의 측정에서 K3의 평가 과제당 비용은 \$0.95였다. 단가가 더 비싼 GPT-5.6 Sol(\$1.04)과는 거의 차이가 없었지만, Claude Fable 5(\$2.75)와 비교하면 약 3분의 1 수준이었다. 즉 비용 절감 효과는 어느 모델에서 갈아타느냐에 따라 크게 달라진다. 참고로 K3는 출시 시점 기준

풀이 길이가 최대로 고정된 상태라 토큰 소모가 가장 많은 조건이며, 예고된 저·중강도 모드가 나오면 과제당 비용은 내려갈 여지가 있다.

여기서 앞의 GPU 비용 표와 이 API 단가표를 이어 보면 중요한 사실이 드러난다. **대부분의 기업에게는 EC2에 직접 호스팅하는 것이 API로 토큰을 사는 것보다 비싸다.** K3의 토큰 단가가 싼 것은 대규모 사업자가 GPU 한 벌을 수많은 고객의 요청으로 꽉 채워 돌리기 때문이다. 개별 기업이 같은 GPU를 EC2에서 빌리면 그 비용을 혼자 부담하므로, 사용량이 적을수록 토큰당 환산 비용은 API보다 몇 배로 비싸진다. 자체 호스팅이 합리적인 경우는 둘뿐이다. GPU를 놀리지 않을 만큼 사용량이 아주 많거나, 데이터를 외부 API로 보낼 수 없어 비용과 무관하게 선택지가 없는 경우다.

5.4 오픈웨이트가 좋아질수록 커지는 시장

위 두 표를 겹쳐 보면 클라우드 사업자와 파트너에게 주는 함의가 분명해진다.

- **모델은 무료지만, 실행은 무료가 아니다:** 오픈웨이트 모델의 가치가 커질수록 그 가치를 현금화하는 지점은 모델 판매가 아니라 GPU 인프라, 호스팅, 운영으로 이동한다. 폐쇄형 모델의 매출이 모델 개발사에 귀속되는 것과 달리, 오픈웨이트 모델의 지출은 클라우드와 인프라 생태계로 흘러든다.
- **성능이 올라갈수록 인프라 장벽도 올라간다:** K3는 최신 288GB급 GPU를 요구하는 첫 오픈 모델이다. 오픈웨이트의 성능 상향은 곧 최신 GPU 세대에 대한 수요 상향이며, 이를 대규모로 보유·운영할 수 있는 주체는 클라우드 사업자뿐이다.
- **중간 사업자의 공간이 생긴다:** 자체 호스팅 비용은 24시간 가동을 전제한 고정비여서, 요청이 없는 시간에도 GPU는 돈을 쓴다. 활용률이 낮은 기업일수록 자체 호스팅이 불리한 이유다. 시간당 126만 원의 권장 구성과 토큰당 과금 사이의 이 간극이 바로 파트너의 사업 공간이다. 여러 고객의 수요를 모아 GPU를 놀리지 않게 하는 호스팅 사업, 축소 구성의 성능·비용 최적화, 미세조정 모델의 프라이빗 서빙, 추론 비용 관리(FinOps)가 모두 여기서 나온다.
- **손익분기 자문이 새 서비스가 된다:** 사용량이 적으면 API, 많으면 자체 호스팅이 유리해지는 교차점이 존재한다. 고객별 워크로드로 이 교차점을 계산해 주는 것 자체가 파트너의 컨설팅 상품이 될 수 있다.

6. AWS 파트너 생태계에 대한 전략적 시사점

6.1 프레임의 전환: ‘어느 모델’에서 ‘어느 조합’으로

K3급 오픈웨이트 모델의 등장으로 고객의 질문이 바뀐다. “가장 좋은 모델이 무엇인가”에서 “우리 워크로드에는 어떤 모델·인프라·도구 조합이 맞는가”로. 이는 단일 모델 벤더보다 선택지를 제공하는 플랫폼과 그 위의 파트너에게 유리한 구도다. Amazon Bedrock의 멀티모델 전략, SageMaker의 커스텀 모델 호스팅은 정확히 이 흐름에 부합한다.

6.2 리스크 축: 규제와 신뢰

중국계 모델에는 성능·비용과 별개의 리스크 축이 있다. 미국 정책 서클에서 중국산 오픈웨이트 모델에 대한 규제 리스크 조성 가능성이 공개적으로 논의되고 있고, 금융·공공 등 규제 산업 고객은 모델 출처(provenance)에 민감하다. 파트너에게 전달할 균형 잡힌 메시지는 다음과 같다.

- 가중치를 자체 인프라에서 돌리는 경우 데이터가 중국 서버로 가는 것은 아니다 — 데이터 경로와 모델 출처는 구분해서 설명할 것.
- 다만 규제 산업 고객에게는 향후 미국·유럽의 규제 변화 가능성을 고지하고, 모델 교체가 가능한 아키텍처를 기본으로 권고할 것.
- 모델 안전성·편향에 대한 독립 평가가 아직 충분치 않다는 점을 투명하게 전달할 것.

7. 우리가 해야 할 일

7.1 기술: 성능 검증, 그리고 그 너머

첫 번째 과제는 당연히 **독립 성능 검증**이다. 7월 27일 가중치가 공개되면 개발사 벤치마크가 아닌 자체 데이터셋과 실제 워크로드로 품질·처리량·비용을 실측해야 한다. 다만 검증은 시작일 뿐이고, 확인해야 할 것이 더 있다.

- **운영 가능성 검증**: K3급 초대형 MoE 모델이 실제로 어떤 인프라 구성(멀티노드 추론, vLLM 등 오픈소스 서빙 스택)에서 안정적으로 돌아가는지, 권장 사양(가속기 64개 이상) 아래의 축소 구성에서는 어느 정도 타협이 가능한지 확인해야 한다. 모델이 좋아도 운영 경로가 없으면 고객에게 권할 수 없다.
- **도구 호환성 검증**: K3는 대화 이력 관리 방식이 특수해서 (thinking 이력 보존 필요), 기존 에이전트 프레임워크나 다른 모델과 혼용하는 환경에서 품질이 불안정해질 수 있다고 개발사가 명시했다. 표준 도구 체인과의 호환성을 실측해 지원 가능 범위를 정의해야 한다.
- **실패 모드 파악**: 벤치마크 점수보다 중요한 것은 어떤 상황에서 어떻게 실패하는가다. 특히 K3는 모호한 지시를 받으면 사용자를 대신해 과감한 결정을 내리는 경향이 보고되어 있으므로, 가드레일 설계 요건을 미리 파악해 둘 필요가 있다.
- **아키텍처 학습**: K3의 효율화 기법(긴 입력을 싸게 처리하는 어텐션, 모델의 일부만 골라 쓰는 구조, 낮은 정밀도 학습)은 추론 비용 구조가 어디로 가는지를 보여준다. 모델 채택 여부와 무관하게, 인프라 용량 계획과 기술 가이드에 반영할 가치가 있다.

7.2 비즈니스: 성능이 다소 낮아도 오픈웨이트가 이기는 자리 찾기

오픈웨이트 모델은 최고 성능 경쟁에서 폐쇄형 최상위 모델에 여전히 뒤진다. 그러나 모든 워크로드에 최고 성능이 필요한 것은 아니다. 실무의 질문은 “어느 모델이 가장 똑똑한가”가 아니라 “이 작업에 충분히 좋으면서 제약 조건을 만족하는 모델이 무엇인가”다. 성능을 일부 양보하더라도 오픈웨이트가 구조적으로 유리한 자리는 분명히 존재하며, 여기서 시사점을 찾아야 한다.

1. **데이터가 밖으로 나갈 수 없는 워크로드**: 의료 기록, 금융 거래 데이터, 국방·공공 기밀처럼 외부 API 전송 자체가 불가능한 영역에서는 성능 순위가 아니라 “자체 인프라에서 돌릴 수 있는가”가 1차 관문이다. 오픈웨이트는 이 관문을 통과하는 사실상 유일한 선택지이며, 이때 비교 대상은 폐쇄형 최상위 모델이 아니라 그 워크로드에 쓸 수 있는 다른 오픈 모델이다.
2. **대량·반복 작업의 비용 최적화**: 문서 분류, 요약, 데이터 추출, 코드 리뷰 보조처럼 건당 난이도는 낮지만 물량이 큰 작업은 최상위 모델을 쓰면 과잉 투자다. “충분히 좋은” 오픈웨이트 모델로 단위 비용을 낮추는 것이 총비용 관점에서 합리적이다.

3. **미세조정이 성능 격차를 뒤집는 영역**: 특정 도메인(법률 문서, 사내 코드베이스, 산업 용어)에서는 범용 최상위 모델보다 해당 데이터로 미세조정된 오픈웨이트 모델이 더 나은 결과를 내는 경우가 많다. 가중치 접근이 가능해야만 열리는 옵션이다.
4. **계층화(cascade) 아키텍처**: 전부를 하나의 모델로 처리할 필요가 없다. 요청의 다수를 저비용 오픈웨이트 모델이 처리하고, 어려운 소수만 폐쇄형 최상위 모델로 올리는 계층 구조는 품질과 비용을 동시에 잡는 실전 패턴이다. 오픈웨이트의 성능이 올라올수록 아래 계층이 감당하는 비중이 커지고 총비용은 내려간다.
5. **벤더 종속·접근 차단 리스크 헤지**: 지난달 미국 정부 지시로 일부 폐쇄형 최상위 모델의 접근이 일시 차단된 사례가 보여주듯, 단일 벤더 의존은 그 자체가 사업 리스크다. 성능이 다소 낮더라도 언제든지 전환 가능한 오픈웨이트 대안을 확보해 두는 것은 보험의 성격을 갖는다.

정리하면, 오픈웨이트 모델의 활용처는 “최고 성능이 필요 없는 곳”이 아니라 **데이터 통제·비용 구조·커스터마이징·연속성이라는 다른 가치가 성능 격차보다 큰 곳**이다. K3의 등장으로 그 격차 자체가 줄어든 만큼, 이 조건을 만족하는 워크로드의 범위는 이전보다 넓어졌다. 우리의 역할은 파트너와 고객이 자기 워크로드가 어느 쪽에 속하는지 판별하도록 돕는 프레임워크를 제공하는 것이다.

8. 맺음말

Kimi K3는 “중국이 미국을 이겼다”는 이야기가 아니다. 최상위권 성능의 모델이 공개된 형태로, 폐쇄형 대비 낮은 단가로 시장에 들어왔고, 그 결과 경쟁의 축이 모델 성능 단독에서 **생태계 — 누가 더 많은 기업과 개발자가 선택하고 운영할 수 있는 환경을 제공하는가** — 로 넓어지고 있다는 이야기다. 선택지가 늘어날수록 고객에게는 선택을 설계해 줄 파트너가, 파트너에게는 어떤 선택이든 감당할 수 있는 플랫폼이 필요해진다. 그 접점을 선점하는 것이 지금 파트너팀이 할 일이다.

주요 출처 (내용은 라이선스 준수를 위해 재구성·요약함)

- Moonshot AI, Kimi K3 공식 발표 블로그: <https://www.kimi.com/blog/kimi-k3>
- Artificial Analysis, “Kimi K3 achieves #3 in the Intelligence Index”: <https://artificialanalysis.ai/articles/kimi-k3-achieves-3-in-the-artificial-analysis-intelligence-index-comparable-to-opus-4-8-and-gpt-5-5>
- Nature, “Does China’s latest AI model finally equal US rivals?”: <https://www.nature.com/articles/d41586-026-02281-2>
- TechCrunch, “Kimi: Threat or menace?”: <https://techcrunch.com/2026/07/18/kimi-threat-or-menace/>
- Forbes, “Chinese AI Startup Moonshot Unveils Kimi K3”: <https://www.forbes.com/sites/tylerroush/2026/07/17/chinese-ai-startup-moonshot-unveils-kimi-k3-model-will-it-challenge-openai-and-anthropic/>
- Hugging Face 커뮤니티 아키텍처 분석: <https://huggingface.co/HFVwr/kimi-k3-article-svg-preview>
- SemiAnalysis의 K3 하드웨어 요건 분석 (implicator.ai 보도): <https://www.implicator.ai/moonshots-kimi-k3-wont-fit-on-a-single-nvidia-dgx-b200/>
- AWS GPU 인스턴스 단가 (2026년 7월 1일 인상 반영 보도): <https://ca.finance.yahoo.com/news/aws-raising-gpu-instance-prices-134610388.html> 및 <https://aws.amazon.com/ec2/pricing/on-demand/>

A. 부록: 핵심 기술 상세 설명

본문 3장에서 요약한 세 가지 효율화 방향(KDA, LatentMoE, MXFP4)에, 층 사이의 정보 흐름을 개선한 Attention Residuals를 더해 네 가지 기술을 자세히 설명한다.

A.1 Kimi Delta Attention

AI 모델은 답을 만들 때 입력된 모든 단어를 서로 비교하는데(어텐션), 기존 방식은 입력이 2배 길어지면 계산량이 4배, 10배 길어지면 100배로 불어난다. 입력 길이의 제곱에 비례해서 늘어나기 때문이다. 긴 문서를 다룰수록 비용이 감당하기 어려운 속도로 커지는 이유가 여기에 있다.

K3는 계산량이 입력 길이에 정비례해서만 늘어나는 새로운 어텐션 방식(KDA)을 전체 어텐션 층의 4분의 3에 적용했다. 입력이 10배 길어지면 계산도 10배만 늘어난다. 나머지 4분의 1은 정확도가 필요한 전체 검색용으로 기존 방식을 유지했다. 100만 토큰이라는 긴 입력을 비교적 낮은 비용으로 제공할 수 있는 구조적 근거다.

이 방식이 K3만의 독자 노선은 아니다. 공개 모델 2,400여 개의 내부 구조를 분석해 온 Hugging Face 커뮤니티 프로젝트(hfviewer)에 따르면, 새로 공개되는 모델 중 이런 선형 방식을 채택한 비율이 1년 전에는 0%에 가까웠으나 최근 분기에는 29%까지 올라왔다. 다만 지금까지는 주로 중소형 모델에서 쓰였고, 최고 성능급 모델에서도 품질 저하 없이 통하는지는 확인되지 않은 상태였다. K3는 2.8조 파라미터의 프런티어급 모델에 이 방식을 적용해 최상위권 성능을 냈다는 점에서, 그 의문에 처음으로 답을 내놓은 사례다.




Figure 1: K3 어텐션 구성의 개념도. 문샷AI 공식 발표의 3:1 구성을 단순화해 나타냈다.

A.2 Attention Residuals

수십~수백 개의 층으로 쌓인 AI 모델에서, 기존 설계는 각 층의 계산 결과가 하나의 통로에 차례로 쌓이며 다음 층으로 전달된다. 앞쪽 층이 만든 정보는 뒤로 갈수록 뒤섞여 희미해지기 쉽다.

K3는 뒤쪽 층이 필요할 때 앞쪽 층의 결과를 선택해서 직접 가져다 쓸 수 있는 연결을 추가했다. 문장 안에서 어떤 단어를 참조할지 고르는 것이 기존 어텐션이라면, K3는 모델의 층과 층 사이에서도 같은 선택을 한다. 공개 모델 2,400여 개의 구조를 분석해 온 hfviewer 프로젝트는 지금까지 추적된 공개 모델 중 이 구조를 쓴 사례가 없다고 평가했다.

A.3 Stable LatentMoE

모델을 여러 전문가 모듈로 나누고 입력마다 일부만 골라 쓰는 MoE 방식 자체는 GPT 계열, DeepSeek 등 여러 프런티어 모델이 쓰는 보편적 기법이다. 차이는 정도에 있다. 기존 모델들이 수십~수백 개의 전문가




Figure 2: Attention Residuals의 개념도. 기존 모델은 정보가 층을 순서대로만 통과하지만, K3는 뒤쪽 층이 앞쪽 층의 결과를 골라 가져올 수 있다.

중 수 개에서 수십 개를 쓰는 수준이라면, K3는 역대 최대인 896개의 전문가를 두고 그중 16개만 골라 쓴다. 전체의 1.8%로, 업계에서 가장 낮은 비율이다.

골라 쓰는 비율이 낮아질수록 총 규모 대비 계산 비용은 줄어들지만, 특정 전문가에만 일이 몰리지 않게 배분하는 문제가 급격히 어려워진다. 문샷AI는 이를 풀기 위한 자체 학습 기법(Quantile Balancing 등)을 함께 제시했고, 이것이 이 규모의 학습을 안정적으로 완주한 비결이라고 설명한다.

A.4 MXFP4

컴퓨터가 숫자를 저장할 때 쓰는 자릿수(정밀도)를 줄이면 모델 크기와 계산 비용이 줄어드는 대신 품질이 떨어질 수 있다. 그래서 대부분의 모델은 높은 정밀도로 학습을 마친 뒤, 배포 직전에 압축한다. 이때 모델은 압축된 상태를 한 번도 경험하지 못한 채 배포되므로 품질 손실이 생긴다.

K3는 반대로 학습 단계부터 4비트라는 낮은 정밀도를 전제하고 훈련했다. 모델이 처음부터 압축된 조건에 맞춰 학습되므로 배포 시점의 품질 손실이 적고, 메모리가 작은 다양한 하드웨어에서 돌리기도 쉬워진다.